PERCOBAAN II

PREPROCESSING

BAB I
PENDAHULUAN

1.1 Latar Belakang

Perkembangan teknologi digital yang pesat telah menghasilkan ledakan *volume* data yang belum pernah terjadi sebelumnya. Fenomena ini dikenal dengan istilah *big data*, yang dicirikan oleh karakteristik 5V yaitu *volume*, *velocity*, *variety*, *veracity*, dan *value*. *Big Data* merujuk pada kumpulan data yang sangat besar dan kompleks sehingga tidak dapat diproses secara efektif menggunakan alat manajemen basis data konvensional. Kondisi ini mendorong lahirnya ekosistem teknologi baru yang dirancang khusus untuk menangani tantangan tersebut, termasuk berbagai platform dan alat yang mendukung proses pengumpulan serta pemuatan data dari berbagai sumber ke dalam lingkungan *big data*, yang dikenal sebagai tahap *data ingestion*. Sebelum data dapat dianalisis lebih lanjut, diperlukan tahap *Exploratory Data Analysis* (EDA) dan *preprocessing* untuk memahami struktur data, mendeteksi anomali, serta membersihkan dan mentransformasi data agar siap digunakan. *Python*, khususnya pustaka *Pandas* dan *Pyspark*[1].

Data yang telah diproses kemudian perlu diorganisasikan melalui *pipeline Extract*, *Transform*, *Load* (ETL) dan disimpan ke dalam *data warehouse* sebagai pusat repositori analitik. Arsitektur ini memungkinkan tim analis untuk mengakses data yang terstruktur, konsisten, dan siap digunakan untuk pengambilan keputusan berbasis data. Puncak dari seluruh rangkaian proses ini adalah tahap analisis data dan pembangunan model klasifikasi. Salah satu pendekatan yang digunakan dalam konteks ini adalah algoritma *Random Forest*, yaitu metode *machine learning* berbasis *ensemble* yang membangun banyak pohon keputusan (*decision tree*) dan menggabungkan hasil prediksinya untuk meningkatkan akurasi serta mengurangi risiko *overfitting*. *Random Forest* bekerja dengan cara melakukan *bootstrap* sampling pada data dan memilih *subset* fitur secara acak pada setiap pohon, sehingga menghasilkan model yang lebih stabil. *Random Forest* digunakan untuk mengklasifikasikan data ke dalam kategori tertentu berdasarkan pola yang telah dipelajari dari data.

1.2 Tujuan

1.2.1 Pengenalan *Big Data*

1. Mahasiswa memahami konsep dasar *Big Data* dan karakteristiknya (5V).
2. Mahasiswa dapat melakukan pengambilan data (*data ingestion*) dari sumber publik dan menyimpannya di *Google Drive*.
3. Mahasiswa mampu melakukan eksplorasi data awal menggunakan *Pandas* seperti menampilkan data, melihat struktur data, dan menggunakan fungsi dasar.

1.2.2 *Preprocessing*

1. Mahasiswa mampu memahami pentingnya kualitas data sebelum analisis.
2. Mahasiswa mampu melakukan pembersihan dan transformasi data.
3. Mahasiswa mampu menyiapkan data yang optimal untuk model *machine learning*.

1.3 Alat dan Bahan

1.3.1 Pengenalan *Big Data*

1. PC/Laptop
2. *Google Colab*
3. *Python*
4. *Pandas*
5. Modul Praktikum

1.3.2 *Preprocessing*

1. PC/Laptop
2. *Google Colab*
3. *Python*
4. *Pandas*
5. Modul Praktikum

BAB II
LANDASAN TEORI

2.1 Teori Dasar

2.1.1 Pengenalan *Big Data*

2.1.2 *Preprocessing*

Data preprocessing adalah proses mempersiapkan data mentah agar siap digunakan dalam analisis atau model *machine learning*. Tahapan ini mencakup pembersihan data, transformasi, integrasi, dan reduksi untuk memastikan data berkualitas tinggi, bebas dari noise, serta dalam format yang sesuai. Dengan *preprocessing* yang baik, model dapat belajar lebih efektif, menghindari bias, dan menghasilkan prediksi yang lebih akurat[2].

Dalam *data preprocessing*, terdapat beberapa tahapan utama yang memastikan data siap digunakan dalam analisis dan *machine learning*. Proses ini bertujuan untuk meningkatkan kualitas data, menghilangkan ketidakkonsistenan, dan mengoptimalkan performa model. Berikut tahapan utama dalam data *preprocessing*:

1. *Data Cleaning*: Data sering kali mengandung kesalahan seperti duplikasi, *missing values*, atau *outlier* yang dapat memengaruhi hasil analisis. Proses *data cleaning* meliputi penghapusan data yang tidak relevan, imputasi *missing values* menggunakan *mean* atau *median*, serta deteksi dan penanganan *outlier* menggunakan metode seperti Z-*score* atau IQR.
2. *Data Integration*: Ketika data berasal dari berbagai sumber, perlu dilakukan *data integration* untuk menggabungkannya menjadi satu *dataset* yang konsisten. Proses ini mencakup penyelarasan format data, eliminasi redundansi, serta penyatuan atribut yang memiliki makna serupa agar dapat dianalisis secara holistik.
3. *Data Transformation*: Agar model *machine learning* dapat memahami data dengan lebih baik, diperlukan data transformation seperti normalisasi (*Min-Max Scaling*) atau standarisasi (Z-*score Scaling*). Selain itu, data kategorikal

dapat dikonversi menjadi format numerik menggunakan teknik *One-Hot Encoding* atau *Label Encoding*, sehingga dapat digunakan dalam algoritma pembelajaran mesin.

4. *Data Reduction*: Untuk menangani *dataset* besar yang berisi banyak fitur, *data reduction* dilakukan guna menyederhanakan data tanpa kehilangan informasi penting.

Lanjutkan penjelasan di disini sampai penuh satu kertas

↓
↓
↓
↓
↓
↓
↓
↓
↓
↓
↓
↓
↓
↓
↓
↓
↓
↓
↓
↓

BAB III

PROSEDUR KERJA

3.1 Langkah Kerja

3.1.1 Pengenalan *Big Data*

3.1.2 *Preprocessing*

1. Masukkan kode berikut untuk melihat informasi *dataset*

```
df = pd.read_csv(drive_path)
df.head(10)

df.info()
```

2. Melihat jumlah *gender dataset*

```
df['gender'].value_counts()
```

3. Melihat distribusi *gender*

```
df['gender'].value_counts().plot(kind='bar', color=['steelblue', 'salmon'])
plt.title('Distribusi Gender')
plt.xlabel('Gender')
plt.ylabel('Jumlah')
plt.xticks(rotation=0)
plt.tight_layout()
plt.show()
```

4. Lakukan langkah *processing* berikut

```
#Prepocessing
df.isnull().sum()
```

5. Visualisasi *outlier* dengan *boxplot*

```
plt.figure(figsize=(10, 8))
df[['forehead_width_cm', 'forehead_height_cm']].boxplot()
plt.title('Boxplot Fitur Numerik Kontinu')
plt.tight_layout()
plt.show()
```

6. Deteksi *oulier* dengan IQR

```
# Deteksi outlier dengan IQR
print("=== Deteksi Outlier dengan IQR ===")
for col in ['forehead_width_cm', 'forehead_height_cm']:
    Q1 = df[col].quantile(0.25)
    Q3 = df[col].quantile(0.75)
    IQR = Q3 - Q1
    lower = Q1 - 1.5 * IQR
    upper = Q3 + 1.5 * IQR
    outliers = df[(df[col] < lower) | (df[col] > upper)]
    print(f"{col}: {len(outliers)} outlier")
```

BAB IV

HASIL DAN PEMBAHASAN

4.1 Hasil dan Pembahasan

4.1.1 Pengenalan *Big Data*

4.1.2 *Preprocessing*

1. Tampilan data teratas

	long_hair	forehead_width_cm	forehead_height_cm	nose_wide	nose_long	lips_thin	distance_nose_to_lip_long	gender
0	1	11.8	6.1	1	0	1	1	Male
1	0	14.0	5.4	0	0	1	0	Female
2	0	11.8	6.3	1	1	1	1	Male
3	0	14.4	6.1	0	1	1	1	Male
4	1	13.5	5.9	0	0	0	0	Female
5	1	13.0	6.8	1	1	1	1	Male
6	1	15.3	6.2	1	1	1	0	Male
7	0	13.0	5.2	0	0	0	0	Female
8	1	11.9	5.4	1	0	1	1	Female
9	1	12.1	5.4	0	0	0	0	Female

2. Informasi *dataset*
3. Tampilan jumlah *gender*
4. Distribusi *gender*
5. Mengecek jumlah data yang kosong (*missing values*)
6. Visualisasi *outlier*
7. Tampilan deteksi *outlier*

BAB V
PENUTUP

5.1 Kesimpulan

5.1.1 Pengenalan *Big Data*

5.1.2 *Preprocessing*

Buatkan kesimpulan minimal 5 baris.

DAFTAR PUSTAKA

[1] S. Sagiroglu and D. Sinanc, "Big data: A review," in *2013 International Conference on Collaboration Technologies and Systems (CTS)*, IEEE, May 2013, pp. 42–47. doi: 10.1109/CTS.2013.6567202.

[2] Digital Skola Content Team, "Data Preprocessing: Definisi, Tahapan, dan Implementasinya," DigitalSkola.